

图片相似度比较与去重工具

该工具使用 `imagehash` 库比较图片相似度，并移除重复的图片。相似度大于阈值的图片会被认为是相似的，即存在重复图片。

安装依赖

在运行该脚本之前，请确保安装了以下依赖库：

```
pip install imagehash pillow numpy
```

使用方法

```
python ./compare.py -i input_dir -t target_dir -o output_dir
```

参数说明

- `-i`, `--input_dir`: 输入目录，即新增数据集，包含要比较的图片。
- `-t`, `--target_dir`: 目标目录，即现有数据集，包含要与之比较的图片。
- `-o`, `--output_dir`: 输出目录，用于暂存非重复的图片，可以。

示例

```
python compare.py -i datasets -t D:project/data/touhou -o temp_datasets
```

在上述示例中，`datasets` 是包含要比较的图片的目录，`D:project/data/touhou` 是包含要与之比较的图片的目录，`temp_datasets` 是用于保存非重复图片的目录。路径兼容相对路径和绝对路径。输入和目标目录结构应该如下所示：

```
+-- datasets/
|   +-- aki_minoriko/
|   |   +-- adjsada.png
|   |   +-- greuiw.png
|   |   +-- fewuiwf.png
|   +-- aki_shizuha/
|   +-- alice_margatroid/

+-- D:project/data/touhou/
|   +-- aki_minoriko/
|   |   +-- 01.png
|   |   +-- 02.png
|   |   +-- 03.png
|   +-- aki_shizuha/
|   +-- alice_margatroid/
```

输出

脚本将输出非重复图片到 `temp_datasets` 目录中，并删除 `datasets` 目录中的重复图片。

注意事项

- 确保输入目录和目标目录存在，并且包含图片文件。
- 输出目录将在运行时自动创建，如果不存在。
- 该脚本会处理 `.png`，`.jpeg`，和 `.jpg` 格式的图片。
- 在处理完后，请检查输出目录中的图片是否满足预期，随后手动添加至目标目录。
- 如果有需要，可以修改脚本中的相似度阈值 `threshold`，如果有较多误判的重复图片，可以适当调低阈值（即认为只有哈希距离更小才应当被判为重复图片，5应该是一个比较合适的值）。